

# Sisteme Inteligente

## Introducere



Universitatea  
Transilvania  
din Brașov



Inteligenţa artificială este un domeniu din ştiinţa calculatoarelor care urmăreşte crearea de maşini inteligente care sunt capabile să lucreze şi să reacţioneze similar ca oamenii.

Problemele fundamentale ale inteligenţei artificiale includ programe de calculator pentru teme cum ar fi:

- Percepţia,
- Cunoştinţele,
- Raţionarea/Analiza,
- Învăţarea,
- Rezolvarea problemelor,
- Planificarea,
- Abilitatea de a manipula şi muta obiecte.



Nu contează dacă inteligența artificială utilizează modelele și mecanismele comportamentului inteligent uman, importantă este capacitatea sistemelor de calcul de a rezolva aceleași probleme cu performanțe similare cu cele ale oamenilor.

**Paradigma Logic-simbolică** presupune mecanisme de reprezentare simbolică a cunoştinţelor şi utilizarea diferitelor modele logice pentru a deduce noi cunoştinţe din faptele memorate în baza de cunoştinţe a sistemului.

**Paradigma Conexionistă** a introdus un nou concept de calcul - *calculul neuronal* - generalizând realizări concrete cunoscute sub numele de *reţele neuronale (neurale) artificiale*.

- Se bazează de cele mai multe ori pe reguli de tipul *IF ... ELSE*;
- Sistemele fuzzy care se bazează pe mulțimile și pe logica fuzzy, sunt parte a acestei paradigme;
- Mulțimile fuzzy sunt înzestrate cu o relație de apartenență gradată, adică un element aparține unei mulțimi cu o anumită probabilitate;
- În logica fuzzy, setul tradițional al variabilelor – adevărat și fals – este înlocuit cu un set de forma – adevărat, fals, “foarte adevărat”, “destul de adevărat”, ... ;
- Din cauza erorilor care afectează măsurătorile în sistemele de reglare devine utilă transformarea valorilor măsurate în valori fuzzy.



- Informația nu mai este memorată în zone bine precizate, ca în cazul calculatoarelor standard, ci este memorată difuz în toată rețeaua;
- Memorarea se face stabilind valori corespunzătoare ale ponderilor conexiunilor sinaptice dintre neuronii rețelei;



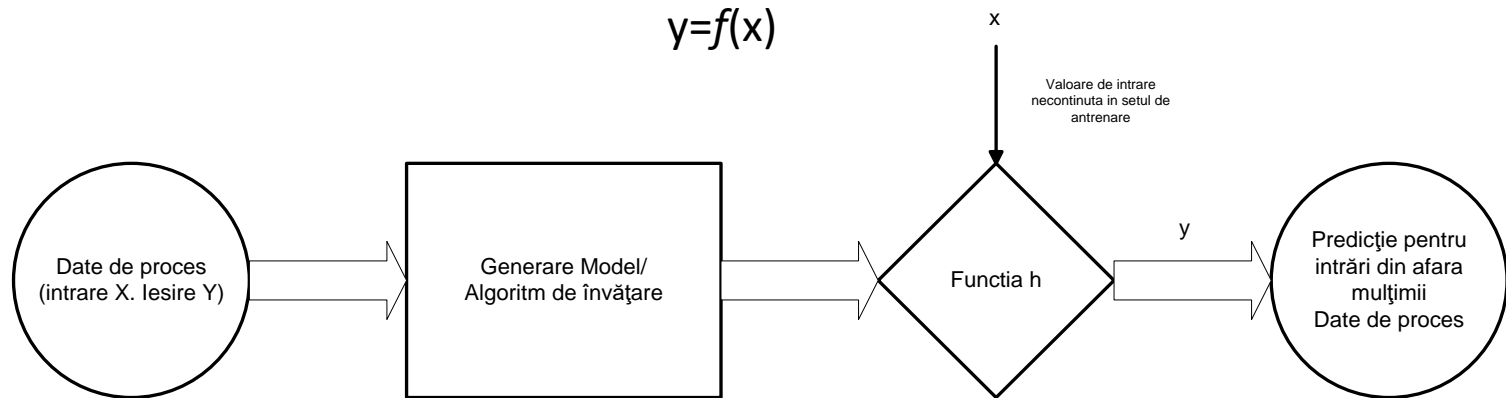
Domeniu de studiu care crează/dă calculatoarelor abilitatea de a învăța fără a fi explicit programate pentru a face aceasta (Arthur Samuel, 1959);

Învățarea poate fi:

- Supervizată;
- Nesupervizată.

## Învăţarea supervizată şi algoritmi

- Procesul de învăţare are ca scop găsirea unei funcţii  $f$  care să aproximeze cât mai bine ieşirea  $y$  a unui sistem când se aplică pe intrare valoarea  $x$ , pornind de la o mulţime de date  $(X,Y)$  –numită mulţimea de date antrenare(“training”) ;



### Algoritmi:

- Regresia liniară;
- Regresie logistică/Clasificare;
- Reţea neuronală;
- ....



Scopul este ca pornind de la setul de date (neetichetate) de la proces să fie identificată o structură a acestor date cu scopul de a învăţa suplimentar despre proces:

- Clustering(grupare) – identificarea datelor din set ce pot fi grupate pe categorii;
- Asociere – identificare de reguli care descriu largi porţiuni din setul de date;

Algoritmi:

- K-means pentru “Clustering”;
- PCA(Principal Component Analysis);
- ....

# Logica & Control Fuzzy



Universitatea  
Transilvania  
din Braşov





## Reprezentarea mulțimilor clasice

$$MF = \{\text{Maria, Magdalena, Marcela}\}$$

$$T = \{x \in \mathbb{Z} \mid x \geq 0\}$$

$$T = \{x \mid P(x)\} \text{ unde } P(x) = x \in \mathbb{Z} \& x \geq 0$$

$$\mu_A = \begin{cases} 1 & \text{daca } x \in A \\ 0 & \text{daca } x \notin A \end{cases}$$

unde  $\mu_A: X \rightarrow \{0,1\}$

## Operații cu mulțimile clasice

Operație	Forma cu predicat	Forma cu funcție indicator
Complement al mulțimii A	$A' = \{x   x \notin A\}$	$\mu_{A'}(x) = 1 - \mu_A(x)$
Intersecția dintre A și B	$A \cap B = \{x   x \in A \ \& \ x \in B\}$	$\mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x))$
Reuniunea dintre A și B	$A \cup B = \{x   x \in A \    \ x \in B\}$	$\mu_{A \cup B}(x) = \max(\mu_A(x), \mu_B(x))$



## Funcția de apartenență

Funcția de apartenență  $\mu_F$  a mulțimii fuzzy  $F$  este o funcție:


$$\mu_F : U \rightarrow [0,1]$$

Enumerarea elementelor unei mulțimi fuzzy se face sub formă de perechi, o pereche fiind constituită din elementul mulțimii și valoarea corespunzătoare a funcției de apartenență:

$$F = \{ (u, \mu_F(u)) \mid u \in U \}$$


## Funcția de apartenență $\Gamma$

$$\Gamma(u; \alpha, \beta) = \begin{cases} 0 & u < \alpha \\ \frac{u - \alpha}{\beta - \alpha} & \alpha \leq u \leq \beta \\ 1 & u > \beta \end{cases}$$




## Funcția de apartenență L

$$L(u; \alpha, \beta) = \begin{cases} 1 & u < \alpha \\ \frac{\beta - u}{\beta - \alpha} & \alpha \leq u \leq \beta \\ 0 & u > \beta \end{cases}$$



## Funcția de apartenență $\Lambda$


$$\Lambda(u; \alpha, \beta, \gamma) = \begin{cases} 0 & u < \alpha \\ \frac{u - \alpha}{\beta - \alpha} & \alpha \leq u \leq \beta \\ \frac{\gamma - u}{\gamma - \beta} & \beta \leq u \leq \gamma \\ 0 & u > \gamma \end{cases}$$





## Funcția de apartenență $\Pi$

$$\Pi(u; \alpha, \beta, \gamma, \delta) = \begin{cases} 0 & u < \alpha \\ \frac{u - \alpha}{\beta - \alpha} & \alpha \leq u \leq \beta \\ 1 & \beta \leq u \leq \gamma \\ \frac{\delta - u}{\delta - \gamma} & \gamma \leq u \leq \delta \\ 0 & u > \delta \end{cases}$$



## Proprietățile seturilor fuzzy (1)

**Suportul** unei mulțimi fuzzy  $A$  este format din elementele universului de discurs  $U$  ce au funcția de apartenență mai mare decât 0:

$$\mathbf{S(A)} = \{ u \in U \mid \mu_A(u) > 0 \}$$

**Lățimea** unei mulțimi  $A$  care este caracterizată de suportul  $\mathbf{S(A)}$  este definită astfel:

$$\mathbf{width(A)} = \sup(\mathbf{S(A)}) - \inf(\mathbf{S(A)})$$

unde:

$\sup(\mathbf{S(A)})$  poate fi definit astfel: dacă  $\alpha = \sup(\mathbf{S(A)})$  atunci

## Proprietăţile seturilor fuzzy (2)

$\inf(\mathbf{S}(\mathbf{A}))$  poate fi definit astfel: dacă  $\beta = \inf(\mathbf{S}(\mathbf{A}))$  atunci

$$(\forall) \ x \in \mathbf{S}(\mathbf{A}), \ x > \beta, \ \mu_A(x) > 0$$

**Nucleul** unei mulţimi fuzzy  $A$  este format din toate elementele care au funcţia de apartenenţă egală cu 1.

$$\mathbf{nucleu}(\mathbf{A}) = \{ u \in U \mid \mu_A(u) = 1 \}$$

**Înălţimea** unui set fuzzy  $A$  este definită de relaţia:

$$hgt(\mathbf{A}) = \sup_{u \in X} \mu_A(x)$$

dacă  $\alpha = \sup_{u \in X} \mu_A(u)$  atunci  $(\forall) x \in \mathbf{S}(\mathbf{A}), \ \mu_A(x) \leq \alpha$

## Caracteristicile unei variabile lingvistice

Prin ***variabilă lingvistică*** înţelegem o variabilă a cărei valoare este reprezentată de cuvinte sau propoziţii într-un limbaj natural sau artificial.

$$\langle X, LX, \mathbf{X}, Mx \rangle$$

unde:

- $X$  este numele simbolic al variabilei lingvistice: vârstă, înălţime, temperatură, eroare, variaţia erorii;
- $LX$  este setul de valori lingvistice pe care-l poate lua  $X$ ;
- $\mathbf{X}$  este domeniul de valori clasice în care variază variabila lingvistică;
- $Mx$  este funcţia care face legătura între valorile lingvistice fuzzy cu valorile cantitative.

$$Mx : LX \rightarrow LX^?$$

unde  $LX^?$  este funcţia ce defineşte fiecare valoare lingvistică.



## Valori lingvistice uzuale în controlul proceselor

**NB – Negative Big**

**NM – Negative Medium**

**NS – Negative Small**

**ZE – Zero**

**PS – Positive Small**

**PM – Positive Medium**

**PB – Positive Big**



*E este NB*

*dacă  $\langle$ propoziție fuzzy $\rangle$  atunci  $\langle$ propoziție fuzzy $\rangle$*

*dacă e este NB și e este PB atunci u este NS*

## Implicația Mandami (1)


$$\mu_{CNS}(\dot{u}) = \min \left( \left( \min_{(e, \dot{e})} \frac{\mu_{NB}(e), \mu_{PB}(\dot{e})}{\phantom{e, \dot{e}}} \right), \mu_{NS}(\dot{u}) \right)$$



## Implicația Mandami (2)

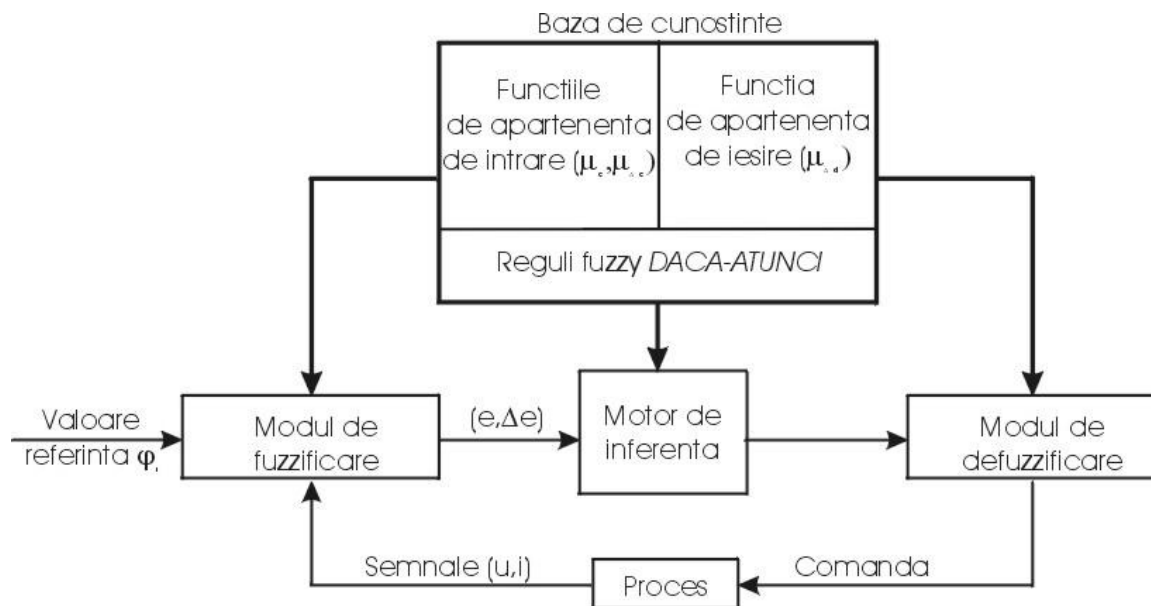
*dacă  $e$  este NB atunci  $u$  este PS*

iar  $e=e^*$  la momentul curent






## Structura unui regulator fuzzy




## Defuzzificare - Metoda centrului de greutate

$$u = \frac{\sum_{i=1}^n u_i \mu_{U_{\mu}}(u_i)}{\sum_{i=1}^n \mu_{U_{\mu}}(u_i)} = \frac{\sum_{i=1}^n u_i \max_k \mu_{U_{C_{\mu}(k)}}(u_i)}{\sum_{i=1}^n \max_k \mu_{U_{C_{\mu}(k)}}(u_i)}$$




## Defuzzificare - Metoda sumei

$$u = \frac{\sum_{i=1}^n u_i \sum_{k=1}^l \mu_{U_{C\mu}(k)}(u_i)}{\sum_{i=1}^n \sum_{k=1}^l \mu_{U_{C\mu}(k)}(u_i)}$$




## Defuzzificare - Metoda înălţimii


$$u = \frac{\sum_{k=1}^n c^{(k)} f_k}{\sum_{k=1}^n f_k}$$




## Defuzzificare - Metoda primului maxim



## Defuzzificare - Metoda ultimului maxim



## Defuzzificare - Metoda mijlocul maximelor



## Regulator cu 2 intrări - 1 ieşire

**e:**

$$\begin{aligned}\mu_{NB}(u) &= L(u, -18, -16), \mu_{NM}(u) = \Pi(u, -18, -16, -8.5, -5.5), \\ \mu_{NS}(u) &= \Pi(u, -8.5, -5.5, -1, 0), \mu_{ZE}(u) = \Lambda(u, -1, 0, 1), \\ \mu_{PS}(u) &= \Pi(u, 0, 1, 5.5, 8.5), \mu_{PM}(u) = \Pi(u, 5.5, 8.5, 16, 18), \\ \mu_{PB}(u) &= \Gamma(u, 16, 18)\end{aligned}$$

**$\Delta e$ :**

$$\begin{aligned}\mu_{NB}(u) &= L(u, -13, -11), \mu_{NM}(u) = \Pi(u, -13, -11, -6, -4), \\ \mu_{NS}(u) &= \Pi(u, -6, -4, -0.5, 0), \mu_{ZE}(u) = \Lambda(u, -0.5, 0, 0.5), \\ \mu_{PS}(u) &= \Pi(u, 0, 0.5, 4, 6), \mu_{PM}(u) = \Pi(u, 4, 6, 11, 13), \\ \mu_{PB}(u) &= \Gamma(u, 11, 13)\end{aligned}$$

**$\Delta y$ :**

$$\begin{aligned}\mu_{NB}(u) &= L(u, -19, -17), \mu_{NM}(u) = \Pi(u, -19, -17, -8, -7), \\ \mu_{NS}(u) &= \Pi(u, -8, -7, -1, 0), \mu_{ZE}(u) = \Lambda(u, -1, 0, 1), \\ \mu_{PS}(u) &= \Pi(u, 0, 1, 7, 8), \mu_{PM}(u) = \Pi(u, 7, 8, 17, 19), \\ \mu_{PB}(u) &= \Gamma(u, 17, 19)\end{aligned}$$



## Tabela de inferenţă

$e \rightarrow$ $\Delta e \downarrow$	NB	NM	NS	ZE	PS	PM	PB
NB	PB	PB	PB	PB	PB	PM	PM
NM	PM	PM	PM	PM	PS	PS	PS
NS	PS	PS	PS	PS	PS	PS	PS
ZE	ZE	ZE	ZE	ZE	ZE	ZE	ZE
PS	NS	NS	NS	NS	NS	NS	NS
PM	NS	NS	NS	NM	NM	NM	NM
PB	NS	NS	NM	NM	NM	NM	NM